

FinLegal AI - Tài Liệu Giải Pháp Công Nghệ & Kiến Trúc Hệ Thống (Technical Architecture & Solutions Mastery)

Dành cho Người Học & Nhà Tuyển Dụng: Tài liệu này trình bày chi tiết toàn bộ các **Giải Pháp Công Nghệ Chuyên Sâu (Technical Solutions)** được xây dựng trong dự án FinLegal AI, bao gồm Bảo vệ chống Spam, Tracing Logs tự xây, Bóc tách PDF FlateDecode & Hex Decoding, Multi-Agent RAG với AgentRouter (gpt-5.6-sol / claude-opus-4-6) và Hạ tầng Cloudflare Serverless Edge.

1. Tổng Quan Các Giải Pháp Công Nghệ Đã Triển Khai (Core Tech Solutions)

flowchart TD

```
User([Người Dùng / Nhà Tuyển Dụng]) --> SecurityGate[1. Security & Anti-Bot Gate\nCloudflare Workers]
SecurityGate --> RateLimiter[2. IP Rate Limiter Middleware\n5 reqs / 10 mins per IP]
```

```
RateLimiter --> API[3. Hono.js Serverless Edge Engine\nCloudflare Workers]
```

```
subgraph Multi-Agent RAG Core (Powered by AgentRouter gpt-5.6-sol)
```

```
  API --> Supervisor[Supervisor Agent\n100% Dynamic AI Intent Routing]
```

```
  Supervisor --> RAG[Advanced RAG Agent\nHybrid Retrieval & PDF Syntax Filter]
```

```
  Supervisor --> SQL[SQL Tool Agent]
```

```
  RAG --> PDFEngine[4. PDF FlateDecode & Hex Decoder\nDecompressionStream + Syntax Noise Reduction]
```

```
  PDFEngine --> Vectorize[(Cloudflare Vectorize\nMultilingual Embedding Index)]
```

```
  SQL --> D1[(Cloudflare D1 SQL DB)]
```

```
  RAG --> Auditor[Risk Auditor Agent\nVietnamese Synthesis & Cross-Check]
```

```
  SQL --> Auditor
```

```
end
```

```
API --> SSE[5. SSE Event Streamer\nReal-time Thought Process]
```

```
API --> InternalLog[6. Custom Internal Tracing System\nD1 chat_logs Table]
```

```
SSE --> FE[Frontend Next.js App\n100% Light Minimal Theme]
```

```
InternalLog --> AdminModal[7. Tracing Logs Dashboard\nAdminLogModal Component]
```

2. Chi Tiết Các Giải Pháp Công Nghệ Chuyên Sâu (In-Depth Technical Solutions)

Giải Pháp 1: Tích Hợp Multi-LLM Provider qua AgentRouter (gpt-5.6-sol / claude-opus-4-6)

- **Bài toán:** Cần sử dụng các mô hình AI đỉnh cao thế hệ mới (2026) để tối ưu khả năng suy luận hợp đồng pháp lý, đối soát dữ liệu và phân tích CV mà vẫn đảm bảo tính linh hoạt hạ tầng.
 - **Giải pháp kỹ thuật:**
 - Xây dựng **Unified LLMProviderService (llm.ts)** hỗ trợ kết nối Proxy Endpoint qua **AgentRouter** (<https://agentrouter.org/v1/chat/completions>).
 - Ưu tiên mô hình **gpt-5.6-sol**, **gpt-5.5**, **claude-opus-4-6**, kết hợp mô hình dự phòng Gemini 2.5 Flash / Workers AI Edge (Llama 3.3 70B, Qwen 14B).
 - Tự động fallback và phục hồi nếu bất kỳ endpoint hay model nào bị nghẽn mạng.
-

Giải Pháp 2: Phân Loại Ý Định 100% Linh Hoạt (100% Dynamic AI Intent Classifier)

- **Bài toán:** Tránh gượng ép luồng xử lý bằng danh sách từ khóa cố định (hardcoded array), đảm bảo AI tự chuyển hướng ý định một cách thông minh.
 - **Giải pháp kỹ thuật:**
 - **Supervisor Agent (supervisor.ts):** Loại bỏ hoàn toàn mảng `docKeywords`.
 - Phụ thuộc 100% vào khả năng hiểu ngữ nghĩa ngôn ngữ tự nhiên của **gpt-5.6-sol** để tự phân loại câu hỏi vào luồng `RAG_ONLY`, `SQL_ONLY`, `HYBRID_AUDIT` hoặc `GENERAL_CHAT`.
-

Giải Pháp 3: Bộ Bóc Tách PDF FlateDecode, Giải Mã Hex & Lọc Rác Cấu Trúc (PDF Hex & Syntax Noise Elimination)

- **Bài toán:** Nhiều file PDF (xuất từ Canva, Adobe hoặc mã hóa font CMap) chứa mã Hex dạng `<362F3230...>` hoặc rác cấu trúc PDF như `/Type`, `/OutputIntent`, `CIDFontType2`, `CIDToGIDMap`, `endobj`, `/StructElem` làm ô nhiễm dữ liệu RAG.
- **Giải pháp kỹ thuật:**
 - **decodeHexPDFString:** Tự động giải mã chuỗi mã hóa Hex dạng `<362F3230...>` thành ký tự Tiếng Việt / ASCII chuẩn (6/2025 - Present).
 - **stripPDFSyntaxNoise & isPDFSyntaxChunk:** Loại bỏ 100% rác lệnh cấu trúc PDF, hủy bỏ tất cả Chunks rác lịch sử trước khi nạp

vào Vectorize hoặc truyền cho LLM.

- **Mô hình $\$0(N)\$$ Zero-Regex Backtracking:** Dùng `indexOf()` tuyến tính quét luồng `stream ... endstream` để triệt tiêu hoàn toàn rủi ro CPU timeout trên Cloudflare Workers.

Giải Pháp 4: Bảo Mật 100% Mã Mã Bí Mật (Zero-Hardcoding & Cloudflare Encrypted Secrets)

- **Bài toán:** Bảo vệ tuyệt đối API Key khỏi rủi ro bị lộ khi push mã nguồn lên Git công khai hay dự án làm việc nhóm.
- **Giải pháp kỹ thuật:**
 - Xóa 100% mã secret Plaintext khỏi file `wrangler.toml`.
 - Sử dụng cơ chế mã hóa Cloudflare Secrets CLI (`npx wrangler secret put OPENAI_API_KEY`) để lưu trữ an toàn trên mạng lưới Edge của Cloudflare.
 - Tích hợp GitHub Repository Secrets (`${{ secrets.CLOUDFLARE_API_TOKEN }}`) vào quy trình CI/CD GitHub Actions (`deploy.yml`).

Giải Pháp 5: Giới Hạn Tần Suất Truy Cập (IP Rate Limiting Middleware)

- **Bài toán:** Bảo vệ tài khoản Cloudflare & API Key khỏi rủi ro bị Bot tự động Spam hay tấn công DDoS.
- **Giải pháp kỹ thuật:**
 - Đọc địa chỉ IP thực tế của người dùng từ header mạng Edge: `c.req.header('cf-connecting-ip')`.
 - Áp dụng cơ chế **Sliding Window 10 phút**: Cho phép tối đa **5 câu hỏi / 10 phút / IP** thông qua D1 Database.

Giải Pháp 6: Hệ Thống Nhật Ký AI Tracing Logs Tự Xây (Internal D1 Observability)

- **Bài toán:** Cần giám sát luồng suy luận của 4 Agent mà không muốn phụ thuộc hoàn toàn vào dịch vụ bên thứ 3.
- **Giải pháp kỹ thuật:**
 - Bảng `chat_logs` lưu trữ trong D1 Database. Giao diện Quản trị `AdminLogModal.tsx` hiển thị từng vết suy luận SSE thời gian thực.

Giải Pháp 7: Quản Lý Vòng Đời & Xóa Dữ Liệu Triệt Để (Document Lifecycle Cleanup)

- **Bài toán:** Người dùng xóa tài liệu khỏi hệ thống một cách an toàn và triệt để.
 - **Giải pháp kỹ thuật:**
 - Endpoint DELETE `/api/documents/:docId`: Tự động xóa file PDF gốc trong Cloudflare R2 Bucket (`finlegal-docs`) và D1 Database (`document_records`).
-

Giải Pháp 8: Luồng Phát Dữ Liệu Thời Gian Thực SSE (Real-time SSE Streaming)

- **Bài toán:** Hiển thị từng bước suy luận của Agent mượt mà theo thời gian thực.
 - **Giải pháp kỹ thuật:**
 - Chuẩn **Server-Sent Events (SSE)** trên Hono.js Worker API truyền sự kiện `thought`, `audit_report`, `final_answer`.
-

3. Bộ Câu Hỏi & Trả Lời Phỏng Vấn Kỹ Thuật (Interview Q&A Flashcards)

Q1: “Kiến trúc LLM Provider của dự án được thiết kế như thế nào để đảm bảo tính sẵn sàng cao?”

Gợi ý trả lời:

“Em xây dựng *Unified LLMPProviderService* hỗ trợ kết nối qua *AgentRouter* với model ưu tiên số 1 là **gpt-5.6-sol** và **claude-opus-4-6**. Nếu kết nối API bị gián đoạn, hệ thống sẽ tự động fallback thông minh sang mô hình *Gemini 2.5 Flash* và các model mã nguồn mở chạy trực tiếp trên *Cloudflare Workers AI Edge* (như *Llama 3.3 70B* và *Qwen 14B*), đảm bảo dịch vụ không bao giờ bị dừng.”

Q2: “Bạn xử lý bài toán bóc tách PDF bị ô nhiễm bởi rác cấu trúc và mã Hex như thế nào?”

Gợi ý trả lời:

“Em xây dựng giải thuật bóc tách 3 lớp:

1. Giải nén luồng nhị phân bằng `DecompressionStream('deflate-raw')`.
2. Giải mã các chuỗi mã hóa Hex dạng `<362F3230...>` thông qua hàm `decodeHexPDFString`.
3. Lọc sạch rác cấu trúc PDF bằng `stripPDFSyntaxNoise`

và *isPDFSyntaxChunk* để hủy bỏ 100% từ mã hệ thống như *CIDFontType2*, *CIDToGIDMap*, *OutputIntent*.
Dữ liệu sau đó được **gpt-5.6-sol** làm sạch và đưa vào Vectorize dưới dạng Standard Markdown chuẩn nét.”

Q3: “Làm thế nào để bạn bảo mật tuyệt đối API Keys trong dự án Cloudflare Workers?”

Gợi ý trả lời:

“Em áp dụng nguyên tắc **Zero Hardcoding**: Xóa toàn bộ secret khỏi file *wrangler.toml*. Các khóa nhạy cảm như *OPENAI_API_KEY* được mã hóa bằng lệnh *wrangler secret put* lưu trên Cloudflare Edge Store, và được truyền vào tiến trình CI/CD qua **GitHub Repository Secrets**, hoàn toàn không bị rò rỉ trên mã nguồn Git.”